

Entendimiento del negocio

Predicción del riesgo de deserción estudiantil en educación superior

DATOS
PARA MÁS
OPORTUNIDADES



Problema y objetivo de negocio



Problema: la institución detecta el abandono cuando ya ocurrió, dificultando una intervención temprana.



Objetivo: identificar anticipadamente estudiantes con riesgo de abandono.



Decisión que apoya: priorizar tutoría, orientación académica y ajuste de carga.



Métrica principal (KPI)



Tasa de Abandono Estudiantil



Qué mide: porcentaje de registros de inscripción que terminan en abandono (Withdrawn).



Unidad de medida: %



Importancia: mide directamente el problema que el proyecto busca reducir.



Cálculo del baseline

Tasa de abandono = $\frac{\text{Registros con abandono}}{\text{Total de registros}} \times 100$ $\frac{10.156}{32.593} \times 100 =$ **31,16 %**



Total de registros
32.593



Abandonos
10.156




No abandonos
22.437

Variable utilizada: final_result → abandono = 1 si Withdrawn; 0 en los demás casos.



Distribución del conjunto de datos



Casi **7 de cada 10** registros no terminan en abandono.



Meta propuesta

Reducir la tasa de abandono estudiantil en el piloto.

31,16 % → 28,0 %



Reducción absoluta
3,16 puntos porcentuales



Reducción relativa
10,1 %



Impacto estimado
≈ 1.030 abandonos evitados

La mejora se presenta como una meta del piloto, no como resultado observado.



ENTENDIMIENTO DE LOS DATOS Y EDA

Open University Learning Analytics Dataset (OULAD)

Predicción del Riesgo
de Deserción Estudiantil



MINERÍA DE DATOS • CRISP-DM

1 ¿QUÉ DATOS TENGO?



Fuente:
OULAD

Open University
Learning Analytics
Dataset



32.593
registros




13
variables

Tipos de variables

- 2 Numéricas discretas
- 7 Categóricas (4 nominales, 3 ordinales)
- 1 Cohorte
- 1 Identificador
- 1 Objetivo (abandono)

2 ¿HAY DATOS FALTANTES?



Variable afectada:

imd_band

1.111 registros vacíos
(3,41 % del total)

Tratamiento



No se eliminan.

El valor faltante se usará
como una categoría propia.

3 ¿EXISTEN VALORES ATÍPICOS?



No se detectaron atípicos
estadísticos tradicionales.



Se identificaron **inconsistencias de formato**
en la variable **imd_band**:

3.516 valores interpretados como fecha
("2020-10-01")




Acción:

Reimportar la columna como texto.

4 ¿CÓMO SE DISTRIBUYEN LOS DATOS?



Distribución del resultado académico



10.156 de **32.593** registros terminaron
en abandono (**31,16 %**).

5 ¿QUÉ RELACIONES EXISTEN ENTRE VARIABLES?



Carga académica vs. tasa de abandono




A mayor carga académica, mayor abandono.

Asociación observada, no implica causalidad.

6 HALLAZGO INTERESANTE



El riesgo de abandono no es uniforme entre módulos



Permite priorizar intervenciones
en los módulos con mayor riesgo de deserción.

